

## 北京市 2014-2015 年空气质量分析

王子翀

2022201379

2025 年 6 月

### 摘 要

本报告基于 2014-2015 年北京市逐日空气质量与气象数据，对六种主要大气污染物（PM2.5, PM10, SO2, NO2, CO, O3）的变化规律与相互作用关系进行了系统性的时间序列分析。研究首先通过可视化分析揭示了各污染物显著的年度季节性模式。随后，在单变量分析框架下，进行 SARIMA, ARIMAX 与 Prophet 模型拟合，比较后两者对 PM2.5 的预测能力，发现两者均能有效捕捉数据的季节性与趋势，其中 ARIMAX 模型因其短期记忆能力在预测精度上略占优势。为了深入探究污染物之间的动态传导机制，本报告的核心部分构建了一个包含六个变量的向量自回归（VAR(2)）模型。模型诊断结果表明该模型设定稳健有效。通过格兰杰因果检验、脉冲响应分析等结构化分析工具，本研究识别出 NO2 和 CO 是整个污染物系统的核心驱动变量，并定量揭示了不同燃烧源对二次污染物生成路径的差异化影响，为理解区域复合型大气污染的成因提供了深刻的洞察。

# 目录

<b>1</b>	<b>背景介绍</b>	<b>1</b>
<b>2</b>	<b>可视化分析</b>	<b>1</b>
<b>3</b>	<b>单变量时间序列分析</b>	<b>3</b>
3.1	季节分解 . . . . .	3
3.2	SARIMA 模型 . . . . .	4
3.3	ARIMAX 模型 . . . . .	4
3.4	Prophet 模型 . . . . .	5
3.5	预测和比较 . . . . .	8
<b>4</b>	<b>多变量时间序列分析</b>	<b>9</b>
4.1	模型选择 . . . . .	9
4.2	VAR 模型 . . . . .	10
4.3	Granger 因果分析 . . . . .	10
4.4	脉冲响应分析 . . . . .	12
4.5	方差分解 . . . . .	14
<b>5</b>	<b>结论</b>	<b>16</b>

# 1 背景介绍

本研究使用的数据来自北京市逐小时空气质量与气象监测数据，时间范围覆盖 2014-2015 年，记录了多个空气污染物的浓度与相关气象条件。该数据集主要用于时间序列建模与预测分析，旨在理解污染物的变化趋势及其与气象因素的关系，为城市环境治理与污染预警提供数据支持。

本报告聚焦以下六种主要污染物：

- **PM<sub>2.5</sub>**（细颗粒物）：指空气中直径小于 2.5 微米的可吸入颗粒物，能够深入肺部并进入血液系统，是影响呼吸系统和心血管疾病的重要因素。
- **PM<sub>10</sub>**（可吸入颗粒物）：包括 PM<sub>2.5</sub> 在内，直径小于 10 微米的颗粒，主要来源为扬尘、建筑工地、交通尾气等。
- **SO<sub>2</sub>**（二氧化硫）：主要来源于燃煤和工业排放，是形成酸雨的前体物之一。
- **NO<sub>2</sub>**（二氧化氮）：与机动车尾气密切相关，可引发呼吸道刺激与雾霾形成。
- **CO**（一氧化碳）：无色无味的有毒气体，主要来源于不完全燃烧，如冬季采暖与交通尾气。
- **O<sub>3</sub>**（臭氧）：在近地面属于二次污染物，通常在强光照条件下由氮氧化物发生光化学反应生成，夏季浓度易升高。

此外，数据集中还包括多个气象变量，如气温、气压、降水等。

# 2 可视化分析

首先对数据进行简单的可视化分析，发现基本规律。在此之前，先使用**线性插值**填补缺失值。

如图 1所示，2014-2015 年北京市主要污染物浓度变化趋势明显，PM<sub>2.5</sub> 和 PM<sub>10</sub> 等大部分污染物的浓度在冬季明显升高，而 O<sub>3</sub> 在夏季浓度较高。

绘制相关系数的热力图（图 2）可以发现，除臭氧外的其他五种污染物有明显的相关关系，集中在热力图的左上角。其中，CO 和其他五种污染物的相关系数都非常高，说明 CO 与其他污染物之间存在较强的线性关系。其他的气象因素（如气温、湿度等）与污染物之间的相关性较弱。

六种主要污染物日均浓度面积图

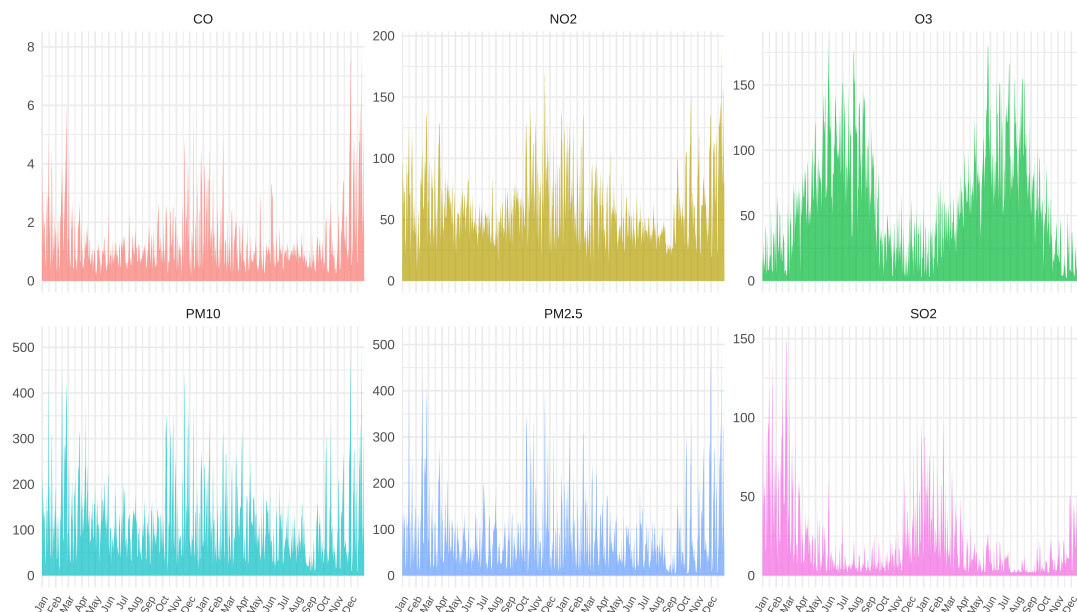


图 1: 北京市 2014-2015 年主要污染物浓度变化




图 2: 北京市 2014-2015 年污染物和气象指标相关系数热力图

### 3 单变量时间序列分析

本小节从一个简单的情形入手：单变量时间序列分析。选择最常见的 PM2.5 作为研究对象，之后再进一步深入。

#### 3.1 季节分解

考虑到工作日和休息日机动车出行的差异，首先考虑按照周来分解。结果如图 3 所示。然而，图中可以看出 Seasonal 的数值量级远小于 Trend 和 Remainder，说明周分解的效果并不理想。从 Summary 得知 Seasonal 仅仅解释 7.8% 的总体变异性。

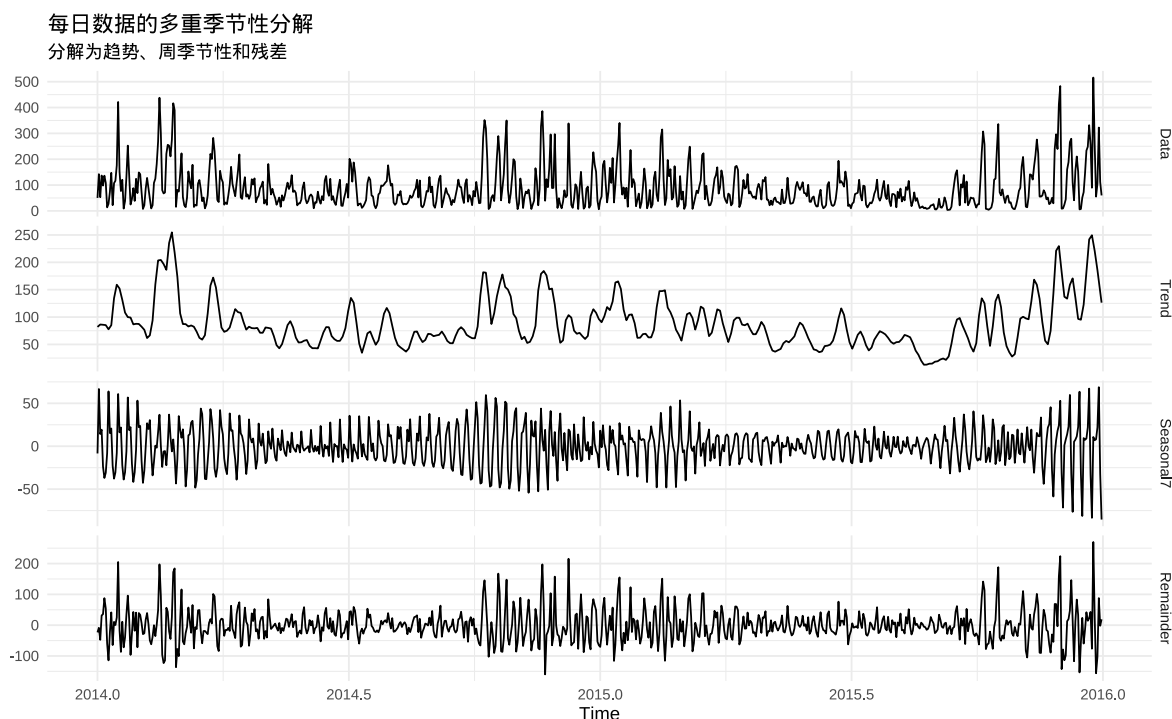


图 3: PM2.5 的周分解结果

单一 Weekly STL 效果较差，然而要进行年度的季节性分析，需要两年以上的数据，数据集的数据量不足以完成。即便如此，分解得到的 Trend 本身就代表了一定的年度模式。

此外，观察小时数据也可以有一些发现。在夏季，一天之内的波动较小，冬季较大，这也与我们的直觉相符。




图 4: PM2.5 的日、周分解结果

### 3.2 SARIMA 模型

从图中可以看出，数据不是白噪声，具有显著的季节性，故直接使用 `auto.arima()` 自动寻找合适的 SARIMA 模型。

结果却出乎我们的意料。算法在比较了大量包含季节性部分和不包含季节性部分的模型之后，根据 AIC 准则，判断出 ARIMA(1,0,1) 模型是最佳模型。残差形态如图 5 所示。LB p-value=0.087。这些表明，残差不是完全白噪声，ACF 也在部分 Lag 处有较大的数值。模型的效果较差，这可能是因为相比年度的波动，一周内的波动振幅较小，而完全被前者“压倒”了。同时，从 MSTL 的结果来看，周季节性模式也不是固定的，振幅在冬季和夏季有较大的差异。标准 SARIMA 模型假设季节性模式是稳定的，故当实际季节性模式不稳定时，模型的拟合能力就会下降。

### 3.3 ARIMAX 模型

ARIMAX 模型不试图用 ARIMA 自身的季节性部分 (P,D,Q) 去硬套复杂的季节规律，而是将模型一分为二：

- 回归部分 (X)：明确地创建外生变量来捕捉季节性模式。使用最为强大的傅立叶项，用若干正弦和余弦函数拟合。

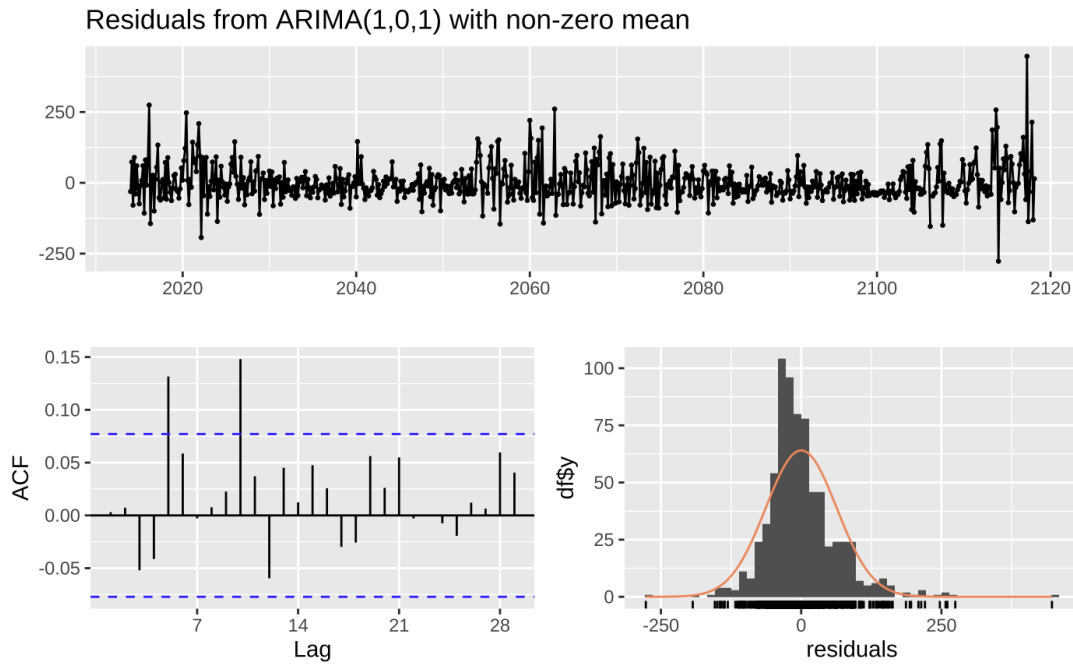


图 5: PM2.5 的 SARIMA(1,0,1) 模型残差分析

- ARIMA 误差部分：在用回归模型提取了季节性之后，剩下的“残差”再由一个标准的、非季节性的 ARIMA 模型来拟合。

具体到本例中，使用 3 对正弦/余弦函数来拟合周期为 7 的模式，用 5 对正弦/余弦函数来拟合周期为 365 的模式。这些傅立叶级数拟合出季节性因素后，使用 ARIMA 模型拟合剩余误差。

最终模型拟合出一个 ARIMA(2,0,3) 模型。残差基本围绕 0 波动，且没有明显的自相关性（图 6）。ACF 中几乎所有的 Lag 都在置信区间内，残差也相对正态。更重要的是，LB p-value = 0.9811，表明残差完全是白噪声。

### 3.4 Prophet 模型

Prophet 模型是 Facebook 开发的一个时间序列预测工具，旨在处理具有强季节性和假期效应的时间序列数据。理念非常直观，认为一个时间序列可以被分解成几个简单部分的加和，背后是贝叶斯推断：

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

其中




图 6: PM2.5 的 SARIMA(1,0,1) 模型残差分析

- $g(t)$  为 trend. 使用分段线性模型, 将时间序列切分成很多短, 每一段用一条独立的直线拟合。
- $s(t)$  为 seasonality. 和 ARIMAX 类似, 使用傅立叶级数来拟合季节性模式。
- $h(t)$  为 holidays. 模型为每一个节假日估算一个独立的效应参数。

模型的主要结果如图 7 所示。黑色的点是真实的数据点, 波动剧烈, 噪声大。深蓝色线是模型的点预测值, 是模型提取出的所有可预测模型 (趋势 + 季节) 的加和。浅蓝色的带状区域是模型的 80% 置信区间。红色实线是识别出的长期趋势相, 呈现缓慢下降。

可以看出, 深蓝色的预测值比原始值平滑的多, 因为忽略了噪声、代表了数据的内在规律, 也完美跟随了数据“冬高夏低”的规律。浅蓝色的区间冬季更宽, 夏季更窄, 这是其贝叶斯特性的强大体现。且真实数据落在区间之外的点大多发生在冬季, 说明冬季的 PM2.5 浓度波动更大。

成分分解图如图 8 所示。可以看到, 趋势部分 (Trend) 是一个缓慢下降的线性趋势, 表明长期的空气质量正在变好。中部的 Weekly 显示一周内的变化。周三的 PM2.5 最低, 周六最高。这可能与一周内工业生产、交通流量的累积和周末的扩散条件变化有关。然而, Weekly 变化的量级在  $\pm 5$  左右, 相对较小。底部的 Yearly 显示了年度变化模式, 呈现出明显的季节性波动。年度的污染高峰在 1 月初, 此时的季节性效应能让



PM2.5 比趋势值高出超过 50 个单位。年度的低谷出现在 9 月份，此时季节性效应会让 PM2.5 比趋势值低近 50 个单位。




图 7: PM2.5 的 Prophet 模型预测结果




图 8: PM2.5 的 Prophet 模型分解结果

### 3.5 预测和比较

由于普通 SARIMA 模型效果较差，仅仅比较 ARIMAX 和 Prophet 模型的预测效果。选择 2014 年 1 月 1 日至 2015 年 12 月 1 日的数据作为训练集，最后 30 天的数据作为测试集。为了作图美观，训练部分仅仅展示一个月。图 9 展示了两模型的预测结果。蓝色的 ARIMAX 预测值和红色的 Prophet 预测值都能较好地跟随实际数据的变化趋势，但蓝色的略好。比较二者的 RMSD，ARIMAX 为 138.69，Prophet 为 155.01，确实前者略好。

ARIMAX 预测波动性更强、效果更好的原因，可能是因为 ARIMA(2,0,3) 部分的短期记忆能力，使得对短期的变化更敏感。Prophet 的预测曲线则更为平滑，这是因为它主要是由几个固定的季节性曲线（年和周）叠加而成，对于短期的随机波动不那么敏感。




图 9: ARIMAX vs Prophet 模型预测结果

总之，对于 PM2.5 的单变量时间序列分析，ARIMAX 模型和 Prophet 模型都能较好地捕捉到数据的趋势和季节性变化。然而，PM2.5 也会受到其他污染物的影响。此前的相关系数热力图显示，PM10、SO<sub>2</sub>、NO<sub>2</sub> 等污染物与 PM2.5 有较强的相关性。如果能利用其他污染物的信息，可能会进一步提高预测精度。

## 4 多变量时间序列分析

根据此前的热力图（图 2），PM2.5 与其他污染物（PM10、SO<sub>2</sub>、NO<sub>2</sub>、CO）有较强的相关性。因此，考虑使用多变量时间序列模型（VAR/VECM）来分析 PM2.5 与其他污染物之间的关系。

VAR(Vector Autoregression) 模型将系统中的每一个变量都看作是它自身以及所有其他变量的过去值的线性函数，捕捉了系统中所有变量之间相互的动态影响。滞后系数为  $p$  的 VAR 可以表示成

$$\mathbf{Y}_t = \mathbf{c} + \mathbf{A}_1 \mathbf{Y}_{t-1} + \mathbf{A}_2 \mathbf{Y}_{t-2} + \cdots + \mathbf{A}_p \mathbf{Y}_{t-p} + \boldsymbol{\varepsilon}_t$$

其中  $\mathbf{Y}_t$  是一个 ( $K \times 1$ ) 的列向量，表示在时间点  $t$  时， $K$  个变量的观测值。 $\mathbf{Y}_{t-i}$  则是在时间点  $t-i$  时， $K$  个变量的观测值。需要估计的参数包括常数项  $\mathbf{c}$  和系数矩阵  $\mathbf{A}_i$ 。

而 VECM(Vector Error Correction Model) 则是 VAR 模型的一个扩展，适用于非平稳时间序列数据。当数据是非平稳的，但存在协整关系，即数据的某个线性组合是平稳的，则可以构建 VECM 模型。本质上即为差分后的 VAR 加上一个误差修正项。

$$\Delta \mathbf{Y}_t = \mathbf{c} + \Pi \mathbf{Y}_{t-1} + \Gamma_1 \Delta \mathbf{Y}_{t-1} + \cdots + \Gamma_{p-1} \Delta \mathbf{Y}_{t-(p-1)} + \boldsymbol{\varepsilon}_t$$

公式和 VAR 类似。不同的点在于误差修正项  $\Pi \mathbf{Y}_{t-1}$ ，代表实际值和长期均衡的偏离程度和修正速度。

### 4.1 模型选择

从 VAR 和 VECM 的公式可以看出，选择模型最重要的点是验证数据的平稳性和协整关系。虽然图 1 的结果显示，似乎数据不是平稳的。但是 ADF 检验的结果表明，所有污染物的时间序列都是平稳的（表 1）。因此，数据不需要差分，直接使用 VAR 模型。

	PM2.5	PM10	SO2	NO2	CO	O3
ADF p-value	<0.01	<0.01	<0.01	<0.01	<0.01	0.042

表 1: ADF 检验结果

## 4.2 VAR 模型

我们通过平稳性检验选择了 VAR 模型。虽然数据是平稳的，但通过此前的分析，我们知道数据存在一定的季节性，否则 ARIMAX 模型不会比 SARIMA 模型明显更好。我们的目标是分析污染物之间内在的、短期的动态关系，剥离季节性效应可以避免强大的季节效应淹没我们真正关心的短期动态。

依然使用傅立叶级数分离季节效应。将污染物对傅里叶项做回归，取其“残差”作为去季节性后的序列。此后用 VARselect() 函数为 VAR 模型选择最佳滞后阶数。根据 AIC 准则选择最佳滞后阶数为 2。

拟合 VAR 模型，所有特征根的绝对值均小于 1，模型稳定。六个污染物的回归 F-test 均显著， $p < 2.2e-16$ ，调整 R 方都在 0.3 左右。每个污染物基本都与 12 个回归自变量中的 3-5 个有显著关系。

模型通过了残差的序列相关性检验 (Portmanteau Test)， $p\text{-value}=0.4184$ ，无法拒绝“残差不存在序列相关”的原假设。这意味着模型已经充分捕捉了数据中的线性动态关系，残差没有什么有用的信息了。

## 4.3 Granger 因果分析

下面进行 Granger 因果分析。表 2 展示了每个污染物对其他污染物的 Granger 因果关系检验结果，研究的是系统的“驱动者”。其中 NO<sub>2</sub> 的显著性最高，表明它是整个污染物系统的核心驱动变量。CO 也非常显著，是系统中的第二大驱动变量。它的历史信息同样能很好地预测其他所有变量。O<sub>3</sub> 的 p 值也小于 0.05，表现出了一定的驱动能力，但其显著性远不如 NO<sub>2</sub> 和 CO。这具有很强的环境意义：控制 NO<sub>2</sub>（主要来自交通和工业排放）是治理整个区域复合型大气污染的核心所在；CO 作为不完全燃烧的标志物，对整体污染有显著影响，监测 CO 的变化可以作为预测整个空气质量恶化的一个重要先行指标；O<sub>3</sub> 是大气中氧化性最强的物质之一，它的变化会影响其他污染物的化学转化过程，也值得注意。剩余的三个污染物则不是系统性的驱动者，历史信息不能很好的预测其他变量的未来。

表 3 展示了每个污染物被其他污染物 Granger 因果关系检验的结果，研究的是系统的“响应者”。该表格中所有 p 值都很小，意味着系统中的每一个变量，其未来的走向都显著地受到其他变量历史信息的影响。这在宏观上证实了大气污染是一个复杂的、多污染物相互作用的系统性问题。我们无法孤立地研究或治理任何一种污染物，因为它的变化总是与其他污染物紧密相连。

Null Hypothesis (H0)	P-value
PM2.5 do not Granger-cause PM10, SO2, NO2, CO, O3	0.4502
PM10 do not Granger-cause PM2.5, SO2, NO2, CO, O3	0.2432
SO2 do not Granger-cause PM2.5, PM10, NO2, CO, O3	0.1005
NO2 do not Granger-cause PM2.5, PM10, SO2, CO, O3	3.482e-12
CO do not Granger-cause PM2.5, PM10, SO2, NO2, O3	1.375e-06
O3 do not Granger-cause PM2.5, PM10, SO2, NO2, CO	0.0347

表 2: Granger Causality Test P-values

Null Hypothesis (H0)	P-value
PM10, SO2, NO2, CO, O3 do not Granger-cause PM2.5	2.039e-08
PM2.5, SO2, NO2, CO, O3 do not Granger-cause PM10	2.593e-10
PM2.5, PM10, NO2, CO, O3 do not Granger-cause SO2	4.619e-09
PM2.5, PM10, SO2, CO, O3 do not Granger-cause NO2	3.502e-06
PM2.5, PM10, SO2, NO2, O3 do not Granger-cause CO	8.791e-07
PM2.5, PM10, SO2, NO2, CO do not Granger-cause O3	0.003297

表 3: Granger Causality Test P-values (Reverse)

## 4.4 脉冲响应分析


Granger 因果分析得知，NO<sub>2</sub> 是系统的核心驱动变量，CO 是第二大驱动变量。因此这里分析 NO<sub>2</sub> 和 CO 对其他污染物的脉冲响应函数（IRF）。当某个污染物发生一个标准差的冲击时，观察对其他污染物未来 20 天的影响。使用 Bootstrap 重复 100 次获取置信区间。

图 10和图 11分别展示了 NO<sub>2</sub> 和 CO 冲击对其他污染物的影响。NO<sub>2</sub> 冲击主要代表高温、高效燃烧过程，如车辆发动机、大型工业锅炉和发电厂。CO 冲击则代表不完全燃烧过程，如汽车尾气、燃煤和生物质燃烧（森林火灾、秸秆）。

对于颗粒物（PM<sub>2.5</sub> 和 PM<sub>10</sub>），二者有着非常差异化的影响。对来自高温燃烧的 NO<sub>2</sub> 冲击，PM<sub>2.5</sub> 和 PM<sub>10</sub> 都做出了显著、迅速且同步的正向响应。响应在第 1-2 天达到峰值，然后快速衰减。这清晰地描绘了二次无机气溶胶的生成路径：高温燃烧产生的大量 NO<sub>x</sub>，通过光化学反应，迅速转化为硝酸盐颗粒，成为 PM<sub>2.5</sub> 的重要组成部分。而对来自低温燃烧的 CO 冲击，PM<sub>2.5</sub> 和 PM<sub>10</sub> 都做出了一个显著的、先下降后上升的“V”型响应。在冲击发生的第 1-2 天，颗粒物浓度不升反降，达到一个低谷，之后才反弹回正值。这个的环境解释较为复杂，可能与某些化学反应有关。总之，两种冲击对颗粒物的影响截然不同，说明它们的来源和化学转化路径有很大差异。

对于气态污染物（SO<sub>2</sub>、NO<sub>2</sub>、CO 和 O<sub>3</sub>），二者的影响则更为复杂，但也更为微弱。NO<sub>2</sub> 对 CO 几乎完全没有影响，说明大气中，NO<sub>2</sub> 不会通过化学反应直接生成 CO，表明其同源而非因果关系。NO<sub>2</sub> 对 SO<sub>2</sub> 的冲击有一个非常微弱、短暂且可能不显著的正向响应，可能其关联主要来自共享的排放源而非化学转化作用。NO<sub>2</sub> 对 O<sub>3</sub> 的冲击则是高中所学的光化学反应 **NO<sub>x</sub> 滴定效应**的经典结果：新增加的 NO<sub>x</sub> 会直接消耗（滴定）大气中背景浓度的 O<sub>3</sub>，导致其浓度下降。CO 对其他气态污染物的影响则更为复杂，对所有气态污染物都有 V 型响应，可能存在一些混淆因素，但通过已有的数据难以进一步得到更多结论。


### Orthogonal Impulse Response from NO2



95 % Bootstrap CI, 100 runs

图 10: NO2 冲击影响

### Orthogonal Impulse Response from CO



95 % Bootstrap CI, 100 runs

图 11: CO 冲击影响

## 4.5 方差分解

我们进一步地进行方差分解 (Forecast Error Variance Decomposition, FEVD), 来量化每个污染物对其他污染物未来波动的贡献。

在 PM2.5 的预测方差中, PM2.5 自身历史冲击的贡献度稳定在 90% 左右。这意味着 PM2.5 有极强的惯性, 一旦污染形成, 其消散过程是缓慢的。在外部贡献中, NO2 是影响 PM2.5 未来不确定性的最重要来源, 其次是 O3 和 CO。这与我们之前的格兰杰检验和脉冲响应分析结果完美契合。

PM10 的预测误差分解中, 自身贡献约占 10%, 来自 PM2.5 的贡献高达 80%。这揭示了颗粒物内部的层级结构。PM10 的预测误差方差中近 80% 是由 PM2.5 的冲击贡献的, 表明 PM10 的动态完全由其细颗粒物部分主导。因此, 控制 PM2.5 是控制整个颗粒物污染的关键。

SO2 的方差分解呈现出独特的模式, 其预测不确定性的 30.6% 可由 PM2.5 的冲击解释。这揭示了两者的可能受到一个共同的、强大的潜在驱动因素 (如区域气象条件) 的影响, 该因素在模型中通过变量间的相互作用得以体现。

NO2 的预测方差也十分反直觉。我们之前认为是系统的核心“驱动者”, 其未来的不确定性竟然有 50% 是由 PM2.5 的冲击所解释的。这表明, 虽然 NO2 是二次颗粒物生成的前体物, 但两者的浓度水平在很大程度上受到共同的强大驱动因素 (尤其是局地 and 区域气象条件) 的协同影响。CO 的情况也类似, 来自 PM2.5 的冲击达到约 75%, 这应该是未知的协同变量的影响。

O3 的动态相对独立, 75% 由自身的光化学过程决定。在外部因素中, NO2 是影响其不确定性的最重要来源, 这与我们已知的 NO<sub>x</sub> 是 O3 生成和消耗的关键前体物的化学知识完全吻合。

因此, 方差分解结果进一步证实了污染物之间的复杂耦合关系和系统性特征。这揭示了在更大的时空尺度上, 一个潜在的、共同的驱动力 (很可能是气象条件) 将 PM2.5, NO2, CO, SO2 等紧密地捆绑在一起, 使得 PM2.5 的“意外”波动成为了衡量这个共同驱动力影响的一个最佳观测指标。



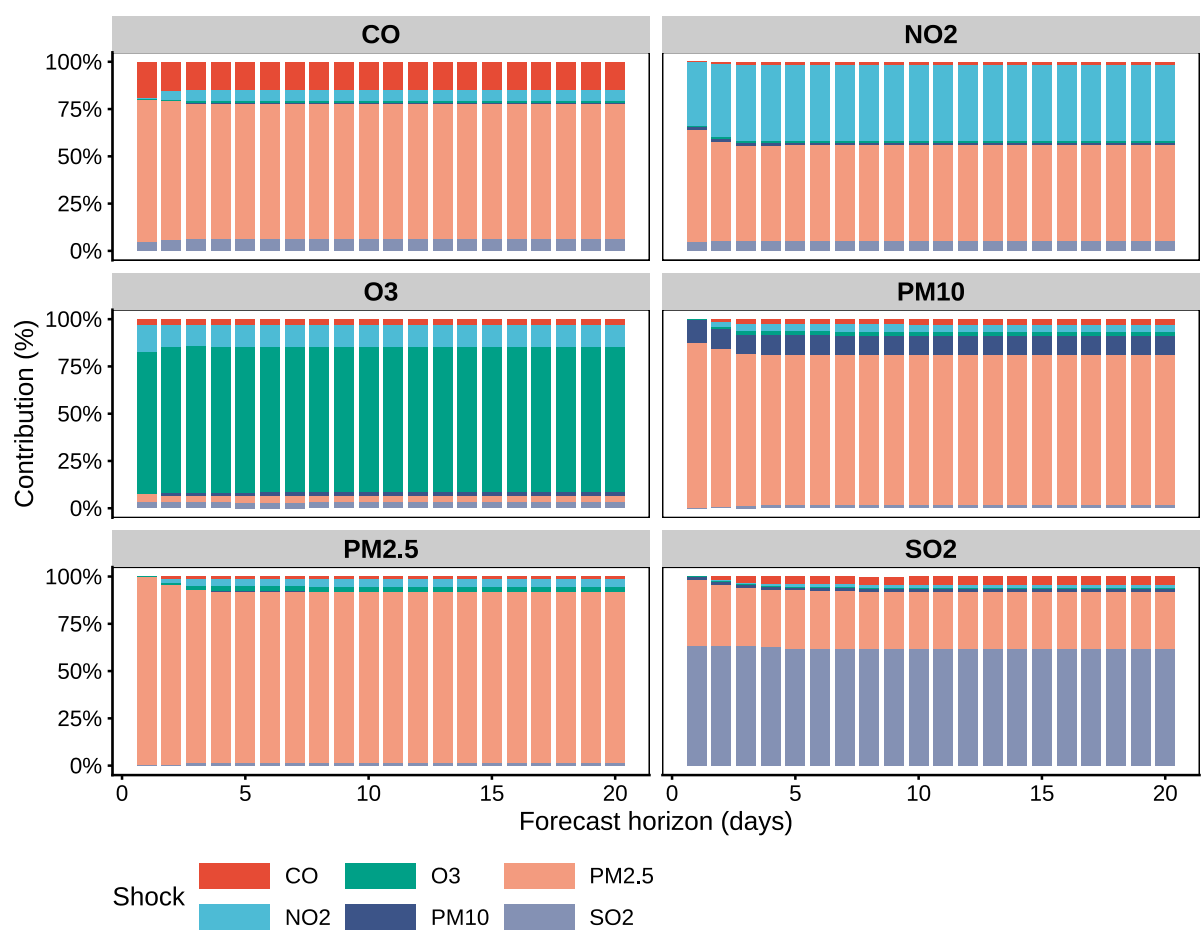


图 12: 方差分解结果

## 5 结论

本研究通过一系列从简到繁的时间序列模型，对北京市 2014-2015 年的空气质量数据进行了全面的剖析，得出以下核心结论：

- **模型适用性与选择：**对于单变量 PM2.5 预测，传统的 SARIMA 模型因无法处理演变季节性而表现不佳。引入外部回归量（傅里叶项）的 ARIMAX 模型和基于加法模型的 Prophet 模型均能显著提升拟合与预测效果。这说明在处理具有复杂季节性的环境数据时，明确地对季节性进行建模是至关重要的。
- **污染物系统的内在结构：**通过构建 VAR(2) 模型，我们证实了六种主要污染物构成了一个高度耦合、相互作用的动态系统。格兰杰因果检验清晰地指出了系统中的“领导-跟随”结构：NO<sub>2</sub> 和 CO 是两大核心驱动变量，其历史信息对系统中其他所有变量的未来走向都具有显著的预测能力，而 PM2.5 等颗粒物更多地扮演了“响应者”的角色。
- **揭示动态传导机制：**脉冲响应分析为我们提供了关于大气化学过程的宝贵洞察。我们成功地区分并量化了两种不同燃烧源的影响路径：
  - 以 NO<sub>2</sub> 为代表的高温、高效燃烧源，其冲击会立即（1-2 天内）、显著地促进 PM2.5 等颗粒物的生成，同时通过滴定效应消耗 O<sub>3</sub>。
  - 以 CO 为代表的不完全燃烧源，其冲击对系统的影响更为复杂，甚至在短期内引发其他污染物浓度的下降，这暗示其影响可能与特定的气象背景条件高度耦合。
- **不确定性的主要来源：**方差分解（FEVD）从贡献度的角度，为我们揭示了系统更深层次的结构和依赖关系，呈现出显著的双重主导特征：一方面，以 NO<sub>2</sub> 和 O<sub>3</sub> 为核心的光化学反应模块表现出强烈的双向依赖，彼此都是对方未来不确定性的重要来源。一方面，一个潜在的、共同的驱动力（推断为区域性气象条件）将 PM2.5、NO<sub>2</sub>、CO 和 SO<sub>2</sub> 等污染物紧密捆绑，使得 PM2.5 成为了衡量这个“污染-气象”复合系统状态的一个最佳综合指标，其随机波动在统计上能够“解释”其他大部分变量的波动。

综上所述，北京 2014-2015 年的大气污染是一个由多污染物、多过程、多尺度相互作用构成的复杂系统。本研究通过 VAR 模型的结构化分析，成功地从数据中解构了这一系统：识别了以 NO<sub>2</sub> 和 CO 为核心的排放驱动，验证了以 NO<sub>2</sub>-O<sub>3</sub>-PM2.5 为链条的

快速化学转化，并揭示了潜在气象因素对整个系统的协同调制作用。这些发现共同指向，有效的空气质量改善策略必须是协同的、有针对性的，并应将对  $\text{NO}_x$  排放的控制置于核心地位。

本研究主要在时间序列的框架内进行，虽然深入揭示了污染物之间的动态关系，但仍存在可拓展的空间。首先，模型中未显式包含气象变量（如风速、气温、湿度），而这些是影响污染物扩散和转化的关键物理因素。未来的研究可以尝试将气象变量纳入模型，以期获得更精确的预测和更全面的解释。其次，本研究主要关注线性关系，而大气过程充满非线性。未来可以探索非线性时间序列模型或基于机器学习的多元预测方法，可能会捕捉到更丰富的动态细节。